Progetto di Fondamenti di Intelligenza Artificiale

SignHelper: Parlare a gesti (riconoscimento del linguaggio dei segni americano)

Vito Gerardo Piegari

Matricola: 0512110333

January 5, 2024

Indice

1 Introduzione

L'atto di comunicare attraverso il linguaggio dei segni, inizialmente appreso dai bambini come un passatempo, si evolve ben presto in una competenza fondamentale che, una volta acquisite le nozioni basilari dell'alfabeto gestuale, consente una comunicazione agevole senza ricorrere alla verbalizzazione.

Tuttavia, vi sono situazioni in cui il linguaggio dei segni non costituisce un mero passatempo ludico, bensì una necessità imprescindibile, specialmente quando sorgono difficoltà nel parlare o sono presenti condizioni di disabilità.

Comprendere e comunicare con il linguaggio dei segni, diventa oltre ad un modo divertente di comunicare, anche un modo per favorire l'**inclusione** nella vita di tutti i giorni di persone che non riescono a comunicare vocalmente.

Nonostante la comprensione del linguaggio dei segni sia relativamente facile per le persone, non si può dire lo stesso per i computer, quindi, questo progetto ha come obiettivo quello di implementare una "semplice" intelligenza artificiale in grado di comprendere brevi parole comunicate con il linguaggio dei segni.

Il sistema sarà implementato come una applicazione che utilizzerà la fotocamera per tracciare le mani e proverà a trascrivere le parole comunicate.

Il link del progetto sarà disponibile al seguente link: https://github.com/veetaw/fia

1.1 Reti neurali

2 Definizione del problema

2.1 Obiettivi

Lo scopo del progetto consiste nel creare una intelligenza artificiale in grado di capire il linguaggio dei segni, associata ad una applicazione per rendere facilmente utilizzabile il sistema all'utente finale.

2.2 Obiettivo dell'agente intelligente

Da scrivereeeeee TODO

2.3 Specifica PEAS

La specifica Peas (Performance Environment Actuators and Sensors) è il primo e fondamentale passo per la formalizzazione del nostro problema attraverso un modello capace di descriverne velocemente le caratteristiche fondamentali. Nel caso di questo progetto, la specifica PEAS dell'ambiente operativo è la seguente:

- **Performance:** La misura di prestazione del sistema si basa sulla capacità dell'agente nella corretta identificazione della singola lettera nell'alfabeto dei segni.
- **Environment:** L'ambiente dell'agente è la foto della mano inviata al classificatore
- **Actuators:** Gli attuatori consistono in un sistema di traduzione della foto ricevuta
- **Sensors:** Il sensore è il sistema di ricezione della foto della mano.

2.4 Caratteristiche dell'ambiente

Dopo aver definito il modello PEAS del nostro problema è fondamentale definirne le caratteristiche dell'ambiente in cui opererà:

- L'ambiente è **Completamente osservabile**, poichè l'agente riceve sempre lo stato completo di esso dato che l'input è una immagine,
- L'ambiente è **Stocastico** poichè l'interpretazione dell'immagine corrente non influenza quella successiva,
- L'ambiente è **Statico** poichè l'agente analizza dei fotogrammi che non possono variare mentre l'agente sta deliberando,
- L'ambiente è **Singolo** poichè ammette un solo agente,
- L'ambiente è **discreto** poichè c'è un numero possibile di azioni finito (le lettere dell'alfabeto trattato sono 24[1]).

[1]Ovviamente le lettere dell'alfabeto sono 26, ma il dataset utilizzato ha evitato le lettere Z e J poichè richiedono movimenti con la mano

3 Dataset

Il dataset che è stato scelto di utilizzare si chiama sign-language-mnist, è disponibile su kaggle al seguente link.
Questo dataset è ispirato al celebre dataset MNIST che tratta di cifre e lettere scritte a mano, ne condivide alcune caratteristiche come la presenza di label e di immagini di dimensione 28x28.

3.1 Struttura

Il dataset è fornito con una serie di immagini suddivise per classi, che indicano la lettera associata al gesto.
Il dataset è provvisto soltanto di 24 delle 26 lettere poichè le lettere Z e J richiedono movimenti della mano.

3.2 Bilanciamento del dataset

Da una prima analisi si evince che il dataset di allenamento è leggermente sbilanciato, quindi sono state necessarie operazioni di data cleaning per evitare

possibili problemi di overfitting causati dalla maggiore presenza di alcune classi rispetto ad altre.

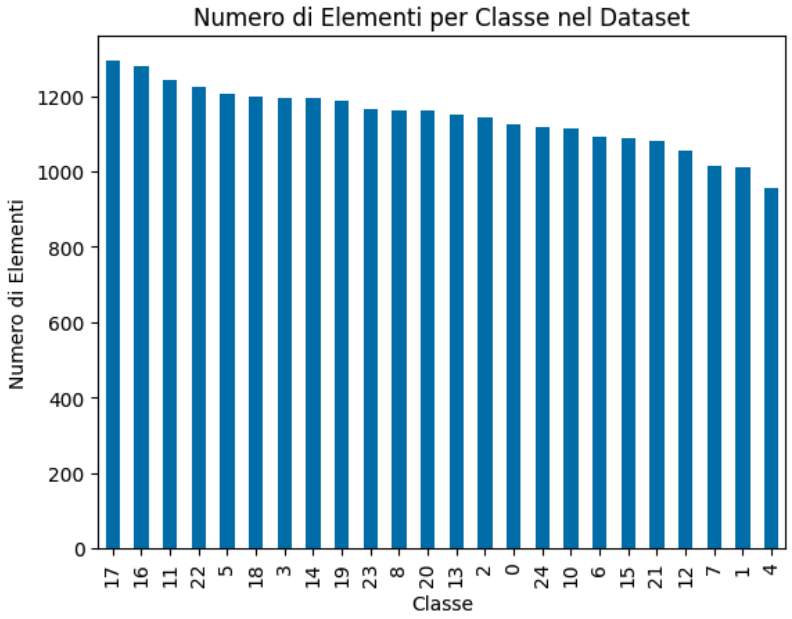

In questo caso è stato scelto di prendere la classe con meno elementi nel dataset e fare undersampling sulle altre classi andando a rimuovere i dati in eccesso per livellare tutte le classi sullo stesso numero di elementi.

```
# Calcola il numero minimo di elementi tra tutte le classi
min_class_count = df['label'].value_counts().min()

# Esegui l'undersampling per ogni classe
undersampled_df = pd.concat([
    df[df['label'] == label].sample(min_class_count, replace=False, random_state=42)
    for label in df['label'].unique()
])

# Effettuo lo shuffle del DataFrame risultante
undersampled_df = undersampled_df.sample(frac=1, random_state=42).reset_index(drop=True)

df = undersampled_df
```

A qusto punto l'operazione di bilanciamento è conclusa poichè il dataset, come si evince dal prossimo grafico, risulta bilanciato.

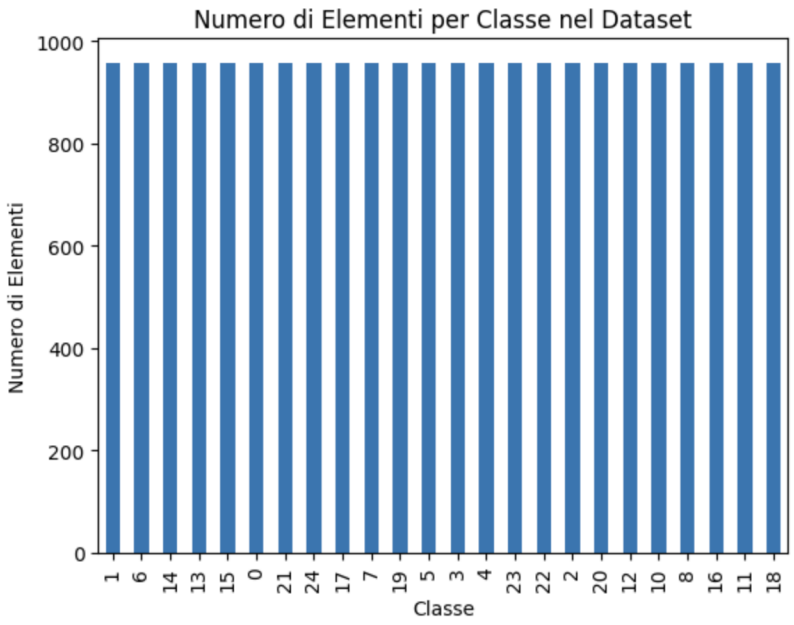

3.3 Ulteriori operazioni sui dati

Dato che il nostro dataset è un csv in cui ogni riga è composta da una label e 784 celle successive, è stato necessario trasformare il vettore dei pixel dell'immagine in una matrice 28x28.

```
train_features = df.iloc[:, 1:].values
train_labels = df.iloc[:, 0].values

train_original_shape = train_features.shape
print("[TRAIN] Original shape:", train_original_shape)

train_features = train_features.reshape(-1, 28, 28, 1)

# Normalizzo le features (che sono i pixel dell'immagine presi uno per uno)
train_features = train_features / 255.0

print("[TRAIN] Current shape:", train_features.shape)
```

```
[TRAIN] Original shape: (22968, 784)
[TRAIN] Current shape: (22968, 28, 28, 1)
```

Notiamo come il risultato dell'operazione di reshaping sia, appunto una matrice 28x28 con un solo canale colore (dato che le immagini sono in scala di grigi).

4 Soluzione proposta

La soluzione proposta è un modello di Machine Learning in grado di riconoscere la lettera associata al gesto fatto con la mano, passato al modello come foto.

4.1 Modello

Il modello scelto è una CNN (Convolutional Neural Network), che ha come obiettivo quello di classificare, tramite varie operazioni, l'immagine a lui inviata e restituirne la classe di appartenenza (in questo caso la lettera).

4.2 Composizione CNN (Convolutional Neural Network)

Nella composizione della rete neurale sono stati utilizzati i seguenti layer:

- **Conv2d** : Questo tipo di layer si occupa dell'operazione di convoluzione, ossia far passare un kernel(filtro) di dimensione 2x2 nell'immagine per iniziare a mappare le caratteristiche dell'immagine. A questo layer è associata la funzione di attivazione ReLU che si occupa di introdurre non linearità

- **MaxPool2d** : Questo tipo di layer non apprende nulla, ma svolge un ruolo importante nella feature extraction, infatti verrà fatto passare un kernel 2x2 nell'immagine e verrà preso il pixel con il valore pià alto. Questo tipo di operazione serve a togliere ancora di più linearità nell'immagine e di conseguenza andare a limitate situazioni di overfitting.

- **Flatten** : Questo layer si occupa di convertire l'output della convoluzione in un vettore monodimensionale. Questo permette di passare dalla rappresentazione spaziale delle caratteristiche estratte dai filtri convoluzionali a una rappresentazione unidimensionale che può essere utilizzata dai layer densamente connessi.

- **Dense** : Questo tipo di layer, anche chiamato layer densamente connesso poichè ogni nodo (neurone) è connesso con tutti i nodi del layer prece-

dente, utilizzato con funzione di attivazione softmax si occupa di creare una distribuzione di probabilità su tutte le classi di output, quindi è il responsabile della predizione del risultato.

Dopo un'analisi iterativa della rete neurale, provando più combinazioni di layer, è stato notato che il miglior risultato è ottenuto con la seguente composizione:

```
Model: "sequential_56"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv2d_156 (Conv2D)         (None, 27, 27, 64)        320

 max_pooling2d_102 (MaxPool  (None, 13, 13, 64)        0
 ing2D)

 conv2d_157 (Conv2D)         (None, 12, 12, 64)        16448

 max_pooling2d_103 (MaxPool  (None, 6, 6, 64)          0
 ing2D)

 conv2d_158 (Conv2D)         (None, 5, 5, 64)          16448

 flatten_43 (Flatten)        (None, 1600)              0

 dense_84 (Dense)            (None, 128)               204928

 dense_85 (Dense)            (None, 25)                3225

=================================================================
Total params: 241369 (942.85 KB)
Trainable params: 241369 (942.85 KB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
```

Inoltre, è stato scelto di usare un kernel di dimensione 2x2 per i layer di convoluzione, poichè:

- Impostando un kernel per il layer convoluzionale 2x2 ho una accuracy del 99% sul dataset di TRAIN dopo 1 epoca, su quello di test 90
- Impostando un kernel per il layer convoluzionale 3x3 ho una accuracy del 95% sul dataset di TRAIN dopo 1 epoca, su quello di test 89

Creata la rete neurale, viene compilato il modello con le API messe a disposizione da Tensorflow, utilizzando i seguenti parametri:

- **Optimizer**: *Adam*, un algoritmo di ottimizzazione che adatta dinamicamente i tassi di apprendimento durante l'allenamento.

- **Funzione di perdita**: *sparse_categorical_crossentropy*, una loss function utilizzata per problemi di classificazione in cui le etichette sono intere, come nel caso studiato.

- **Metriche**: è stato deciso di usare l'*accuracy* come metrica da monitorare durante l'allenamento del modello, ricordando che l'accuratezza è calcolata come $Accuracy_{modello} = \frac{(TP+TN)}{(TP+TN+FP+FN)}$.

4.3 Integrazione nell'Applicazione

5 Conclusioni e sviluppi futuri

5.1 Conclusioni

5.2 Sviluppi futuri

6 Sviluppi Futuri